

Análise e Previsão de Atrasos em Voos Domésticos nos EUA

Ciência de Dados — Relatório Intercalar (Parte 1)

Micael Gonçalves

Faculdade de Ciências Exatas e da Engenharia

Universidade da Madeira

Funchal, Portugal

2033117@student.uma.pt

Resumo—Este relatório apresenta as três primeiras fases do ciclo de vida de análise de dados aplicadas ao *Flight Delay and Cancellation Dataset (2019–2023)*, disponibilizado pelo Departamento de Transportes dos Estados Unidos da América. O objetivo principal é prever e analisar atrasos em voos domésticos norte-americanos, abordando tarefas de regressão, classificação, clustering e testes de hipóteses. Este documento cobre a formulação do problema, a análise e limpeza dos dados, a análise exploratória, os testes de hipóteses e a seleção de modelos, incluindo engenharia de features e avaliação de modelos baseline.

Palavras-chave—atrasos em voos, machine learning, análise de dados, regressão, classificação, Python, R

I. FORMULAÇÃO DO PROBLEMA

A. Descrição do Dataset

O dataset utilizado neste projeto é o *Flight Delay and Cancellation Dataset (2019–2023)*, disponível na plataforma Kaggle [1]. Este dataset é derivado do sistema de reporte de pontualidade (*On-Time Performance Reporting System*) do Departamento de Transportes dos EUA e contém informação detalhada sobre voos domésticos comerciais operados por companhias aéreas norte-americanas.

Cada linha do dataset corresponde a um único voo comercial doméstico agendado, com colunas que cobrem informação sobre o voo, horários agendados e reais, atrasos, distâncias e indicadores operacionais. As principais categorias de variáveis são:

- **Informação do voo:** data, companhia aérea, códigos de origem e destino, número de voo.
- **Horários agendados e reais:** tempos de partida e chegada, tempos de taxi, tempo no ar.
- **Métricas de atraso:** atraso na partida (`DEP_DELAY`), atraso na chegada (`ARR_DELAY`), causas de atraso.
- **Duração e distância:** tempo de voo agendado (`CRS_ELAPSED_TIME`), distância (`DISTANCE`).
- **Indicadores de estado:** voo cancelado (`CANCELLED`), voo desviado (`DIVERTED`).

B. Problema

O problema central deste projeto é a previsão e análise de atrasos em voos domésticos nos EUA. O objetivo é identificar

os fatores que influenciam os atrasos na chegada e prever esses atrasos antes da partida, utilizando apenas informação disponível antes do voo.

C. Objetivos

Os objetivos deste projeto são:

- **Regressão:** Prever a duração do atraso na chegada (em minutos) com base em horários agendados, companhia aérea, rota, distância e fatores operacionais.
- **Classificação:** Reformular a previsão de atrasos como um problema de classificação com 3 classes: *on-time* (atraso < 15 min), atraso curto (15–30 min) e atraso longo (> 30 min).
- **Clustering:** Identificar padrões de desempenho operacional em aeroportos e/ou companhias aéreas com base em perfis de atraso.
- **Testes de hipóteses:** Validar estatisticamente hipóteses sobre fatores que influenciam os atrasos.

D. Critérios de Sucesso

O sucesso deste projeto é medido pela capacidade de prever e categorizar atrasos em voos com base em informação conhecida antes da partida. Para a tarefa de regressão, o sucesso implica erros de previsão razoavelmente baixos. Para a classificação, o sucesso é definido pela correta identificação de voos *on-time*, com atraso curto e com atraso longo, com elevada precisão e *recall*. A análise exploratória e o clustering deverão revelar padrões significativos no desempenho operacional, e os testes de hipóteses deverão fornecer conclusões estatisticamente válidas.

II. ANÁLISE E LIMPEZA DOS DADOS

A. Pré-processamento

1) *Limpeza Inicial:* A limpeza inicial dos dados envolve os seguintes passos:

- Remoção de voos cancelados ou desviados, uma vez que estes não possuem valores de atraso na chegada significativos.
- Remoção de linhas com valores em falta em `CRS_ELAPSED_TIME` e `ARR_DELAY`.

- Filtro de distâncias fora do intervalo válido [50, 5500] milhas. Voos abaixo de 50 milhas são provavelmente erros de dados ou voos de ferry não representativos de operações comerciais. Nenhuma rota doméstica nos EUA excede 5500 milhas.
- *Clipping* de valores negativos de `ARR_DELAY` para 0, tratando chegadas antecipadas como equivalentes a chegadas pontuais. Esta decisão foi tomada com base em orientação do docente.

Após esta limpeza, o dataset resultante contém aproximadamente 2.9 milhões de registros.

2) *Remoção de Colunas com Data Leakage*: Para garantir a validade e justiça dos modelos preditivos, foram removidas todas as colunas que contêm informação posterior ao evento ou que codificam diretamente a variável alvo. As colunas removidas incluem tempos reais de partida e chegada, tempos de taxi, tempo no ar, tempo de voo real, e as colunas de causas de atraso (`DELAY_DUE_*`). Identificadores administrativos como `DOT_CODE`, `FL_NUMBER` e `AIRLINE_DOT` foram também removidos por não serem relevantes para a previsão.

3) *Tratamento de Outliers*: O método IQR (*Interquartile Range*) foi aplicado à coluna `CRS_ELAPSED_TIME` para detectar valores extremos. Os outliers identificados foram substituídos pela mediana da coluna, preservando o tamanho do dataset em vez de remover linhas. A mediana foi preferida à média por ser ela própria robusta a valores extremos.

4) *Normalização e Estandarização*: Para preparar as features numéricas para PCA e outras análises, foram aplicados dois métodos de scaling às colunas `CRS_ELAPSED_TIME`, `DISTANCE`, `CRS_DEP_TIME` e `CRS_ARR_TIME`:

- **Estandarização (Z-score)**: centra as features em torno de 0 com desvio padrão 1. As versões estandarizadas (`_std`) são utilizadas para PCA e UMAP.
- **Normalização Min-Max**: escala as features para o intervalo [0, 1]. As versões normalizadas (`_minmax`) são retidas para potencial uso em modelos baseados em distância nas fases posteriores.

B. Análise Exploratória dos Dados (EDA)

Nota: A EDA foi realizada sobre os dados após limpeza inicial de linhas (voos cancelados/desviados e valores em falta removidos, filtro de distâncias aplicado), mas antes do clipping de `ARR_DELAY`, preservando a distribuição original para exploração.

1) *Estatísticas Descritivas*: As estatísticas descritivas das principais features numéricas revelam:

- A **duração média agendada** (`CRS_ELAPSED_TIME`) é de aproximadamente **142 minutos**, com mediana de **125 minutos**, indicando que a maioria dos voos é de curta a média distância.
- A **distância média** é de cerca de **811 milhas**, com mediana de **654 milhas**, sugerindo que o dataset contém maioritariamente rotas domésticas de média distância.
- O **atraso médio na chegada** (`ARR_DELAY`) é de aproximadamente **4.26 minutos**, com mediana de **-7 minutos**,

indicando que muitos voos chegam ligeiramente antes do previsto.

- O **desvio padrão dos atrasos** (≈ 51 minutos) é relativamente elevado comparado com a média, indicando grande variabilidade no comportamento dos atrasos.
- O **atraso máximo** registado excede **2900 minutos**, representando outliers extremos provavelmente causados por eventos meteorológicos severos ou atrasos em cascata.

2) *Distribuição por Companhia Aérea*: A análise das top 10 companhias aéreas por número de voos mostra que a **Southwest Airlines Co.** é a maior companhia no dataset, com aproximadamente **600.000 voos registados**. A **Delta Air Lines Inc.** e a **American Airlines Inc.** aparecem como segunda e terceira maiores, cada uma com aproximadamente **400.000 voos**.

3) *Análise de Histogramas*: Os histogramas das principais variáveis numéricas revelam:

- A maioria dos voos tem `CRS_ELAPSED_TIME` entre **80 e 145 minutos**.
- O histograma de `DISTANCE` mostra que a maioria dos voos cobre **100–1000 milhas**, com poucos voos acima de 4000 milhas.
- O histograma de `ARR_DELAY` mostra que a maioria dos voos chega pontualmente, com o pico de densidade em torno de **0 minutos**, e uma cauda direita indicando atrasos ocasionais.
- Os histogramas das causas de atraso mostram que a maioria dos voos experimenta atrasos mínimos de cada causa, sendo os atrasos meteorológicos e do sistema nacional de espaço aéreo (NAS) ligeiramente mais comuns.

4) *Atraso por Companhia Aérea*: A análise de boxplots de `ARR_DELAY` por companhia aérea mostra que a maioria das companhias tem mediana de atraso próxima de 0 minutos. Algumas companhias apresentam medianas ligeiramente negativas, indicando que os seus voos tendem a chegar ligeiramente antes do previsto. Existe uma cauda longa de outliers com atrasos superiores a 25 minutos, bem como alguns outliers do lado das chegadas antecipadas.

5) *Correlações*: A análise da matriz de correlação revela:

- `ARR_DELAY` apresenta a correlação mais forte com `DEP_DELAY` (**0.96**), confirmando que atrasos na partida são o principal driver de atrasos na chegada.
- Outras correlações notáveis com `ARR_DELAY`: `DELAY_DUE_CARRIER` (0.68), `DELAY_DUE_LATE_AIRCRAFT` (0.50), `DELAY_DUE_WEATHER` (0.30), `DELAY_DUE_NAS` (0.22), `TAXI_OUT` (0.19).
- `CRS_ELAPSED_TIME` e `ELAPSED_TIME` apresentam correlação de **0.98**, e `AIR_TIME` e `DISTANCE` de **0.98–0.99**, refletindo as suas definições complementares.

Note-se que `DEP_DELAY` e as colunas `DELAY_DUE_*` são variáveis de *data leakage* e não serão utilizadas como preditores nos modelos.

C. Redução de Dimensionalidade

1) **PCA:** A Análise de Componentes Principais (PCA) foi aplicada às features estandardizadas CRS_ELAPSED_TIME_std, DISTANCE_std, CRS_DEP_TIME_std e CRS_ARR_TIME_std. Os dois primeiros componentes principais explicam aproximadamente **85% da variância** total das features selecionadas.

A projeção 2D mostra algum agrupamento subtil por companhia aérea, embora a maioria das companhias se sobreponha consideravelmente, indicando que operam em intervalos similares de horários e distâncias. O PCA confirma que a maioria da variação no dataset é explicada pela duração agendada e distância.

2) **UMAP:** O UMAP (*Uniform Manifold Approximation and Projection*) foi aplicado às mesmas features estandardizadas usadas no PCA, sobre uma amostra aleatória de 200.000 voos para tornar o cálculo viável. Os parâmetros utilizados foram `n_neighbors=50` e `min_dist=0.1`.

A projeção UMAP revela clusters distintos, embora sobrepostos, refletindo que algumas companhias têm padrões de voo característicos em termos de distância e horários agendados. Companhias como a *Horizon Air*, *Mesa Airlines* e *Endeavor Air* mostram-se ligeiramente separadas do cluster principal, enquanto as grandes companhias como a *Southwest*, *Delta* e *American* estão mais próximas entre si. Comparativamente ao PCA, o UMAP captura relações não-lineares, revelando padrões menos visíveis em projeções lineares.

D. Testes de Hipóteses

Foram formulados e testados cinco pares de hipóteses para avaliar estatisticamente relações entre as características dos voos e os atrasos na chegada. Diferentes métodos estatísticos foram aplicados consoante o tipo de variáveis analisadas: correlação de Pearson para variáveis contínuas, e testes t e ANOVA para comparações de médias entre grupos.

1) **H1: Correlação entre Distância e Atraso na Chegada:**
H₀: Não existe correlação entre DISTANCE e ARR_DELAY.
H₁: Existe correlação significativa entre DISTANCE e ARR_DELAY.

O teste de correlação de Pearson produziu um coeficiente de correlação de **0.014** e um p-value de **0.000**. Embora estatisticamente significativo, o coeficiente é extremamente próximo de zero, pelo que a relação é **praticamente negligenciável**. A distância de voo não influencia de forma significativa os atrasos na chegada.

2) **H2: Comparação de Médias entre Southwest e Delta:**
H₀: O atraso médio na chegada da Southwest Airlines Co. é igual ao da Delta Air Lines Inc.
H₁: O atraso médio na chegada difere significativamente entre as duas companhias.

Um teste t de duas amostras independentes (Welch) produziu uma estatística t de **3.142** e um p-value de **0.002**. Rejeitamos H₀, concluindo que existe uma diferença estatisticamente significativa entre os atrasos médios das duas companhias.

3) **H3: ANOVA entre Todas as Companhias Aéreas:** **H₀:** Todas as companhias aéreas têm o mesmo atraso médio na chegada.

H₁: Pelo menos uma companhia tem atraso médio significativamente diferente.

A ANOVA unidirecional produziu uma estatística F de **714.138** e um p-value de **0.000**. Rejeitamos H₀, confirmando que existem diferenças significativas nos atrasos médios entre companhias aéreas.

4) **H4: Correlação entre Atrasos Meteorológicos e Atraso na Chegada:** **H₀:** Não existe correlação entre DELAY_DUE_WEATHER e ARR_DELAY.

H₁: Existe correlação significativa entre atrasos meteorológicos e ARR_DELAY.

O teste de Pearson produziu um coeficiente de **0.30** e p-value de **0.000**. Os atrasos meteorológicos têm um impacto estatisticamente significativo nos atrasos na chegada. *Nota: este teste foi realizado nos dados antes da remoção das colunas de leakage, sendo utilizado apenas para fins exploratórios.*

5) **H5: ANOVA por Hora de Partida Agendada:** **H₀:** Os atrasos médios na chegada são iguais para todas as horas de partida agendadas.

H₁: Os atrasos médios diferem entre horas de partida agendadas.

A ANOVA produziu uma estatística F de **842.402** e p-value de **0.000**. Rejeitamos H₀, indicando que a hora de partida tem um impacto estatisticamente significativo nos atrasos na chegada, provavelmente devido a congestionamento de tráfego aéreo e padrões operacionais dos aeroportos.

III. SELEÇÃO DE MODELOS

A. Engenharia de Features

Antes da seleção de modelos, foram criadas mais de 10 novas features para enriquecer o dataset:

- **Encoding categórico:** *One-Hot Encoding* para AIRLINE_CODE e *Label Encoding* para ORIGIN e DEST.
- **Binning:** `dep_time_bin` (hora de partida em 4 intervalos), `flight_duration_bin` (duração em 4 categorias), `distance_bin` (distância em 4 categorias).
- **Features de interação:** `elapsed_x_distance` (produto de duração e distância), `dep_hour_x_elapsed` (produto de hora de partida e duração).
- **Features temporais:** DAY_OF_WEEK, MONTH, IS_WEEKEND, IS_RUSH_HOUR, DEP_HOUR.

B. Modelos Candidatos

Para o problema de regressão (previsão de ARR_DELAY), foram considerados e justificados os seguintes modelos:

- **Regressão Linear:** modelo baseline simples, interpretável, adequado para estabelecer uma referência de desempenho.
- **Random Forest Regressor:** modelo de ensemble capaz de capturar relações não-lineares e interações entre features, mais adequado para a complexidade do problema.

Nas fases seguintes do projeto serão implementados e avaliados modelos adicionais, nomeadamente: kNN implementado de raiz em NumPy, pelo menos dois modelos de aprendizagem supervisionada adicionais via sklearn, dois modelos de ensemble (um com bagging e um com boosting), um modelo de deep learning em TensorFlow ou PyTorch, e pelo menos dois algoritmos de clustering.

C. Método de Validação

O dataset foi dividido em conjuntos de treino (80%) e teste (20%) utilizando uma divisão aleatória. Esta abordagem é adequada dado o elevado volume de dados disponível (≈ 2.9 M registos), tornando o custo computacional da validação cruzada proibitivo nesta fase. O método de validação mais adequado será reavaliado consoante os modelos implementados nas fases seguintes.

D. Avaliação dos Modelos

Os modelos foram avaliados com as métricas MAE, RMSE e R^2 , e os resultados são apresentados na Tabela I.

Tabela I
COMPARAÇÃO DE MODELOS BASELINE

Modelo	MAE	RMSE	R^2
Regressão Linear	19.474	47.859	0.011
Random Forest	19.239	47.945	0.007

Ambos os modelos produziram resultados muito semelhantes, com R^2 abaixo de 0.015, indicando que os modelos explicam menos de 1.5% da variância nos atrasos na chegada. Este resultado é esperado e explica-se principalmente pela exclusão estrita de variáveis de *data leakage*, que incluem os preditores mais informativos como DEP_DELAY e as causas de atraso. Os modelos representam assim um cenário **realista de previsão pré-partida**.

A análise de importância de features do Random Forest destacou variáveis temporais e features de interação engineered como os principais contribuidores para as previsões, confirmando que padrões temporais e operacionais têm um papel relevante nos atrasos de voos.

As fases seguintes (Parte 2) incluirão a implementação de kNN de raiz em NumPy, pelo menos dois modelos supervisionados adicionais via sklearn, dois modelos de ensemble (bagging e boosting), um modelo de deep learning em TensorFlow ou PyTorch, e pelo menos dois algoritmos de clustering, culminando numa comparação completa de modelos e num plano de operacionalização.

IV. CONCLUSÃO

Este relatório apresentou as três primeiras fases do ciclo de vida de análise de dados aplicadas ao dataset de atrasos em voos domésticos nos EUA. O pré-processamento produziu um dataset limpo com aproximadamente 2.9 milhões de registos, após remoção de voos cancelados/desviados, tratamento de valores em falta, outliers e colunas de data leakage. A análise exploratória revelou que a maioria dos voos opera próximo do

horário previsto, mas com elevada variabilidade nos atrasos. Os testes de hipóteses confirmaram estatisticamente que a companhia aérea e a hora de partida influenciam significativamente os atrasos. Os modelos baseline estabeleceram uma referência de desempenho que servirá de comparação para modelos mais avançados nas fases seguintes.

REFERÊNCIAS

- [1] P. Zel, "Flight Delay and Cancellation Dataset (2019–2023)," Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/patrickzel/flight-delay-and-cancellation-dataset-2019-2023/data>